

RoadSafe LLM FineTuning

Product Requirements Document

프로젝트 기간: 2026년 5월 21일 ~ 2026년 5월 31일

1. 제품 개요

RoadSafe LLM FineTuning은 교통사고 상황 설명을 입력받아 사고 구조, 핵심 쟁점, 확인 필요 자료, 대처 방향, 주의 문구를 생성하는 법률 도메인 특화 LLM 시스템이다.

본 제품은 사용자의 사고 설명을 직접 법적 판단으로 확정하지 않는다. 대신 RAG 기반 근거 검색, Multi-Stage FineTuning, Safety Filter를 결합하여 사고 상담 보조에 적합한 구조화 답변을 제공한다.

본 PRD는 요구사항 분석서에서 도출된 요구를 제품 기능, 시스템 구성, 학습 전략, 평가 계획으로 구체화한다.

2. 제품 범위

구분	내용
포함 범위	텍스트 기반 교통사고 상황 분석, 법률/과실 쟁점 정리, RAG 근거 검색, 안전 후처리, Flask REST API 서빙
제외 범위	블랙박스 영상 직접 분석, 최종 법률 자문 또는 판결 대체, 실시간 웹 검색 기반 답변, 의료 진단
향후 확장	블랙박스 영상 및 이미지 분석은 향후 VLM 기반 멀티모달 확장 과제로 정의한다.

제품 범위는 텍스트 기반 LLM/RAG 시스템으로 제한한다. 영상 분석은 현재 버전의 직접 기능이 아니라, 향후 RoadSafe Vision 또는 VLM 기반 모듈과 연계할 수 있는 확장 방향으로만 둔다.

3. 핵심 사용자 흐름

PRD의 사용자 흐름은 요구사항 분석서의 사용자 유형 표를 반복하지 않고, 제품 내부 처리 관점에서 정의한다.

단계	제품 동작
1. 입력	사용자가 사고 상황을 자연어 텍스트로 입력한다.
2. 정규화	Input Normalizer가 사고 주체, 도로 환경, 위험 키워드를 확장한다.
3. 긴급상황 확인	Emergency Router가 부상, 2차 사고, 화재, 고속도로 정차 등 긴급 키워드를 우선 점검한다.
4. 근거 검색	Hybrid Retriever가 BM25와 FAISS 검색 결과를 병합한다.
5. 프롬프트 구성	Prompt Builder가 검색 근거, Rule Card, 답변 형식을 조합한다.
6. 답변 생성	Fine-tuned LLM이 구조화된 사고 분석 답변을 생성한다.
7. 안전 검증	Safety Filter가 단정 표현, 위험 조언, 필수 주의문 누락을 점검한다.
8. 응답 반환	Flask REST API가 구조화 답변을 웹 UI 또는 클라이언트에 반환한다.

4. 핵심 기능 설계

기능	제품 설계
사고 상황 분석	입력 문장에서 교통 주체, 장소, 진행 방향, 충돌 지점, 위험 요인을 추출한다.
사고 유형 분류	차 대 차, 차 대 보행자, 차 대 자전거, 차 대 PM, 비정형 사고 등으로 분류한다.
Hybrid RAG 검색	BM25의 키워드 검색과 FAISS의 의미 검색을 결합한다.
Rule Card 적용	핵심 도로교통 규칙을 카드화하여 검색 boost와 답변 누락 방지에 활용한다.
구조화 답변 생성	상황 요약, 사고 유형, 사실관계, 확인 필요, 관련 근거, 핵심 쟁점, 대처 방법, 주의 섹션을 생성한다.
비정형 케이스 처리	야생동물, 결빙, 차량 고장, 도로 낙하물 등을 판단 축으로 분해한다.
안전장치 후처리	과실 단정, 법률 판단 확정, 위험한 조언을 차단하거나 완화한다.

5. 시스템 아키텍처

전체 파이프라인은 다음 컴포넌트 순서로 구성한다. 특수 기호나 코드 블록 대신 표 기반으로 구성하여 문서 출력 안정성을 높인다.

순서	컴포넌트	역할
1	User Input	사용자 사고 설명 텍스트 입력
2	Input Normalizer	자연어 표현을 사고 분석 키워드로 확장
3	Emergency Router	긴급상황 감지 시 안전조치와 신고 안내 우선
4	Hybrid Retriever	BM25와 FAISS 검색 결과 병합 및 재정렬
5	Rule Card / Category Boost	사고 유형별 핵심 규칙과 카테고리 가중치 반영
6	Prompt Builder	검색 근거와 답변 형식을 프롬프트로 구성
7	Fine-tuned Llama 3.2 3B	사고 구조와 사용자 QA 형식에 맞는 답변 생성
8	Safety Filter	위험 표현, 단정 표현, 근거 부족 상태 후처리
9	Flask REST API	웹 UI 또는 외부 클라이언트로 응답 반환

컴포넌트	세부 설명
Input Normalizer	야간, 무단횡단, 자전거횡단도, PM, 전방주시 등 도메인 키워드를 확장한다.
Emergency Router	부상, 2차 사고, 차량 화재, 고속도로 정차 등 즉시 대응이 필요한 상황을 우선 처리한다.
Hybrid Retriever	법률 용어 정확 검색과 사용자 자연어 의미 검색을 함께 수행한다.
Safety Filter	과실비율 확정, 신고 회피, 허위 진술 유도, 법적 책임 단정 표현을 탐지하고 완화한다.

6. 기술 스택 및 선택 근거

기술/구성	선택 근거
Llama 3.2 3B Base	로컬 GPU 환경 제약을 고려하면서 QLoRA 기반 한국어 도메인 파인튜닝이 가능한 경량 LLM이다.
Multi-Stage QLoRA	법률 언어 적응, 사고 구조 학습, 사용자 QA, hard case correction을 단계적으로 분리한다.
PEFT / LoRA	전체 모델을 재학습하지 않고 적은 GPU 메모리로 도메인 특화 학습을 수행한다.
4bit Quantization	RTX 3070 8GB 환경에서 3B 모델 학습과 추론을 가능하게 하기 위한 메모리 절감 전략이다.
ko-sroberta 계열 임베딩	한국어 법률/교통 문서와 사용자 자연어 질문의 의미 매칭에 활용한다.
FAISS	로컬 벡터 인덱스를 사용하여 이식성과 시연 안정성을 확보한다.
BM25 + FAISS Hybrid	법률 키워드 정확 검색과 자연어 의미 검색을 동시에 보완한다.
Safety Filter	법률 도메인에서 위험한 단정 표현을 차단하는 출력 후처리 계층이다.
Flask REST API	기존 웹 UI 또는 포트폴리오 웹사이트와 연동하기 쉬운 경량 서버 방식이다.

7. Multi-Stage FineTuning 전략

FineTuning은 하나의 데이터셋으로 한 번에 끝내지 않고, 모델이 학습해야 하는 능력을 단계별로 분리한다. 각 Stage는 별도 adapter와 평가 결과를 남겨 추후 되돌아갈 수 있도록 구성한다.

Stage	목표	주요 산출물
Stage 1	도로교통 법률 언어 적응	Law DAPT 데이터셋, stage1 adapter, train/eval metrics
Stage 2	사고 구조와 과실 쟁점 학습	Accident Structure SFT 데이터셋, stage2 adapter, 사고 구조 평가 결과
Stage 3	실사용 QA 응답 형식 학습	User QA 데이터셋, stage3 adapter, 샘플 답변 비교
Stage 4	오답 기반 hard case correction	Hard case correction 데이터셋, 전후 비교 평가 결과
Final	RAG + Safety Filter + API 통합	FAISS/BM25 인덱스, Rule Card, Flask API, 최종 시연 패키지

7.1 RTX 3070 8GB 기준 QLoRA 초기값

항목	초기값
rank / lora_alpha / dropout	16 / 32 / 0.05
learning_rate / epochs	2e-4 / 3
batch 전략	batch 1, gradient accumulation 16, effective batch 16
도전값	batch 2, gradient accumulation 8
max_seq_length	1024, OOM 발생 시 768 또는 512로 하향
optimizer	paged_adamw_8bit
precision	fp16 사용, bf16 비활성화
gradient checkpointing	활성화

8. RAG 및 Safety Filter 설계

법률과 과실 쟁점은 모델의 내부 기억에만 의존하지 않고 검색 근거를 우선 활용한다. RAG는 법령, 생활법령, 과실 기준, 판례/분쟁 사례, Rule Card를 검색하여 Prompt Builder에 전달한다.

구성	설계 방향
문서 청킹	법령은 조항, 생활법령은 섹션, 사례 자료는 사고 유형 중심으로 분할한다.
검색 결합	BM25와 FAISS 점수를 min-max normalize 후 가중합으로 결합한다.
Rule Card	핵심 도로교통 규칙을 짧은 카드로 요약해 검색과 답변 생성에 활용한다.
Safety Filter	금지 표현, 단정 표현, 근거 부족 상태, 필수 주의문 누락을 점검한다.
Fallback	검색 confidence가 낮거나 정보가 부족하면 단정 대신 추가 확인 자료를 요청한다.

9. 평가 계획

평가 계획은 요구사항 분석서의 인수 조건을 정량화한 제품 검증 기준이다. 모델 loss만으로 판단하지 않고 retrieval, generation, safety, hard case, end-to-end 관점에서 함께 평가한다.

평가 영역	지표
Retrieval	top-k hit율, MRR, category hit, rule card hit, 정답 근거 chunk top-3 포함 여부
Generation	필수 섹션 포함률, 필수 키워드 포함률, faithfulness, 사고 주체 혼동 여부, 핵심 수정 요소 누락 여부
Safety	과실비율 단정 표현 탐지, 법적 책임 확정 표현 탐지, 필수 주의문 포함 여부
Hard Case	Stage 4 전후 오답 유형 감소, 비정형 사고 불확실성 명시 여부

평가 영역	지표
End-to-End	실제 사용자형 질문에 대한 구조화 답변 품질, 근거 일치성, 추가 확인 자료 안내 여부

항목	초기 목표
Retrieval top-3 hit율	80% 이상
Rule Card top-3 hit율	85% 이상
필수 섹션 포함률	95% 이상
위험 표현 탐지	평가셋 기준 0건 목표
정보 부족 질문 단정 표현	0건 목표
Hard Case 개선	Stage 4 전후 비교 시 주요 오답 유형 감소

10. 개발 마일스톤

기간	작업 내용
2026.05.21 ~ 2026.05.22	사전 문서 작성, 기술 스택 확정, 프로젝트 범위 정의
2026.05.23 ~ 2026.05.24	원자료 정리, 구조 기반 청킹, Rule Card 초안 작성
2026.05.25 ~ 2026.05.26	Stage 1 Law DAPT 데이터 생성 및 학습, TensorBoard 기록
2026.05.27 ~ 2026.05.28	Stage 2 사고 구조 데이터 생성 및 학습, retrieval 평가셋 구성
2026.05.29	Stage 3 사용자 QA 학습, 출력 형식 및 안전장치 검증
2026.05.30	Stage 4 hard case correction, 전후 비교 평가
2026.05.31	최종 API 패키징, 보고서/트러블슈팅 정리, 웹 연동 확인

11. 최종 산출물

구분	산출물
모델	Stage별 adapter, merged model, RoadSafe final fine-tuned model
RAG	traffic law chunks, precedent chunks, rule cards, FAISS index, BM25 index
평가	baseline/stage별 eval 결과, retrieval eval, safety eval, hardcase 전후 비교, TensorBoard 캡처
서빙	RoadSafe LLM API, Flask app.py, retriever.py, prompt builder, safety filter, answer engine
문서	PRD, 요구사항 분석서, 최종 보고서, 트러블슈팅 보고서, 실험 결과 보고서, 데이터 출처 정리 문서

RoadSafe LLM FineTuning은 도로교통법, 생활법령, 판례, 과실비율 자료를 기반으로 다양한 정형/비정형 교통사고 상황을 사고 구성요소로 분해하고, Hybrid RAG와 Multi-Stage FineTuning LLM, Safety Filter를 결합해 법률 도메인 신뢰성을 고려한 구조화 답변을 제공하는 것을 목표로 한다.